Esquemas para XML

Vanessa Braganholo vanessa@ic.uff.br

Esquema XML

- Esquema XML: um vocabulário específico
- Pode ser associado a um documento XML
 - O documento tem que seguir as "regras" do vocabulário/esquema associado

Esquema XML × Esquema Relacional

SGBD Relacional

- Esquema: estrutura das tabelas
- Instância: tuplas

XML

- Esquema: vocabulário que define regras que os documentos XML devem seguir
- Instâncias: documentos XML

Doc. XML Bem-formado x Válido

- Documento XML bem-formado: documento que segue as regras de formação do XML (raiz única, bem aninhado, etc.)
- Documento XML válido: documento bem-formado que segue as regras de um esquema associado

Como seria este esquema?

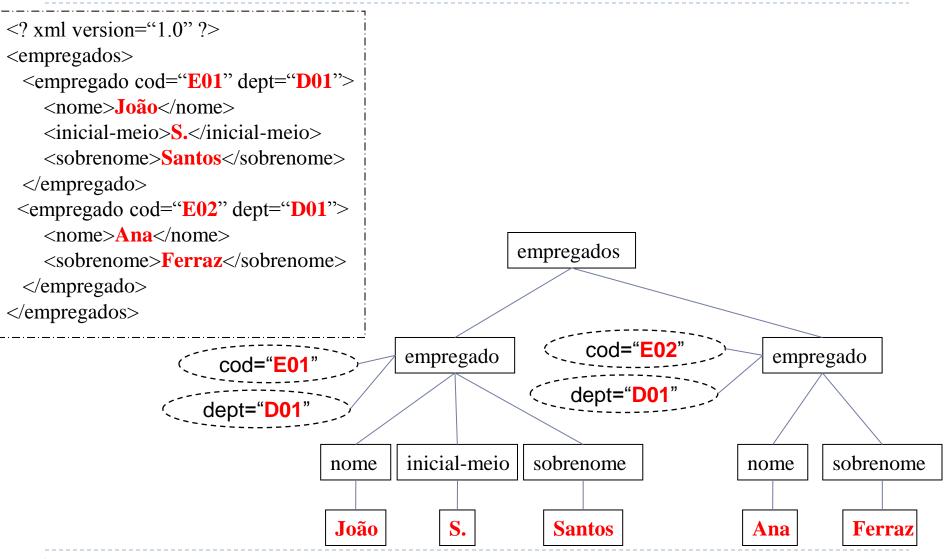
- DTD Document Type Definition
 - Gramática Regular
- XML Schema
 - Esquema escrito em XML

DTD - Document Type Definition

DTD (http://www.w3.org/TR/2008/REC-xml-20081126/#dt-markupdecl)

- Define as regras de formação dos elementos e atributos
 - Quais os elementos que podem aparecer em um documento
 - Em que ordem eles podem aparecer
 - Qual a hierarquia permitida para os elementos
 - Quais os atributos que um elemento pode conter

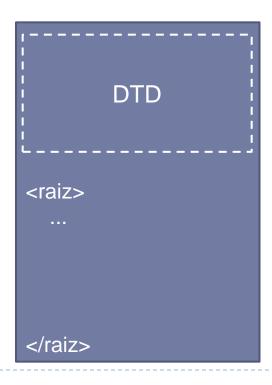
Exemplo que será utilizado na aula



Local da Declaração

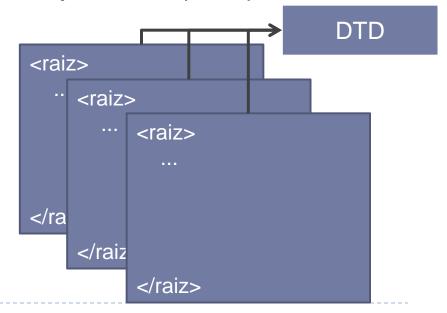
DTD Interna

 Definida dentro do documento XML



DTD Externa

 Definida fora do documento XML, em um arquivo fisicamente separado (.dtd)



DTD interna – no arquivo xml

```
<? xml version="1.0"?>
<!DOCTYPE empregados [</pre>
<!ELEMENT empregados (empregado+)>
<!ELEMENT empregado (nome, inicial-
meio?, sobrenome)>
<!ATTLIST empregado
         cod CDATA #REQUIRED
         dept CDATA #REQUIRED
<!ELEMENT nome (#PCDATA)>
<!ELEMENT inicial-meio (#PCDATA)>
<!ELEMENT sobrenome (#PCDATA)>
]>
<empregados>
 <empregado cod="E01" dept="D01">
    <nome>João</nome>
    <inicial-meio>S.</inicial-meio>
    <sobrenome>Santos</sobrenome>
 </empregado>
 <empregado cod="E02" dept="D01">
    <nome>Ana</nome>
    <sobrenome>Ferraz</sobrenome>
 </empregado>
</empregados>
```

DTD externa – arquivos físicos separados

```
<!ELEMENT empregados (empregado+)>
 <!ELEMENT empregado (nome, inicial-meio?, sobrenome)>
 <!ATTLIST empregado
                 cod CDATA #REQUIRED
                 dept CDATA #REQUIRED
 <!ELEMENT nome (#PCDATA)>
                                                             Arquivo emp.xml
 <!ELEMENT inicial-meio (#PCDATA)</pre>
                                      <? xml version="1.0"?>
 <!ELEMENT sobrenome (#PCDATA)</pre>
                                      <!DOCTYPE empregados SYSTEM (emp.dtd)</pre>
                                      <empregados>
                                        <empregado cod="E01" dept="D01">
                                          <nome>João</nome>_-
                                          <inicial-meio>S.</inicial-meio>
                                          <sobrenome>Santos</sobrenome>
Arquivo emp.dtd <
                                        </empregado>
                                       <empregado cod="E02" dept="D01">
                                          <nome>Ana</nome>
                                          <sobrenome>Ferraz</sobrenome>
                                        </empregado>
                                      </empregados>
```

Declaração da DTD

```
<? xml version="1,0"?>
<!DOCTYPE empregados SYSTEM "emp.dtd">
<empregados>
 <empregade cod="E01"dept="D01">
    <nome>João ~ nome>
    <inicial-meio>S.</n>
    <sobrenome>Santos</s
 </empregado>
 <empregado cod="E02" dept="D01">
    <nome>Ana</nome>
    <sobrenome>Ferraz</sobrenome>
 </empregado>
</empregados>
```

Nome do tipo de documento e do elemento raiz devem ser **IGUAIS**

Declaração de Elemento

<!ELEMENT empregados (empregado+)>

Existe um elemento **empregados**, cujo conteúdo é constituído de um ou mais elementos **empregado**

No documento XML

```
<empregados>
    <empregado>...</empregado>
    <empregado>...</empregado>
    <empregado>...</empregado>
    <empregado>...</empregado>
</empregados>
```

Cardinalidade

- Cardinalidade: + * ?
 - + um ou mais
 - * zero ou mais
 - ? zero ou um
 - Se não houver símbolo de cardinalidade ao lado do elemento, ele é obrigatório

Exemplo

<!ELEMENT empregado (nome, inicial-meio?, sobrenome)>

O elemento empregado é composto de 3 sub-elementos: **nome** (obrigatório), **inicial-meio** (opcional), e **sobrenome** (obrigatório)

No documento XML

Sequência e Escolha

<!ELEMENT empregado (nome, inicial-meio, sobrenome)>
O elemento empregado é composto de 3 sub-elementos: nome, inicial-meio, e sobrenome, nessa ordem

<!ELEMENT empregado (nome | inicial-meio | sobrenome)>
 O elemento empregado é composto de 1 sub-elemento: ou nome ou inicial-meio ou sobrenome

Sequência e Escolha

<!ELEMENT empregado (nome, inicial-meio, sobrenome)>

<!ELEMENT empregado (nome | inicial-meio | sobrenome)>

Elemento Textual

<!ELEMENT nome (#PCDATA)>

#PCDATA significa *Parsable Character Data*, ou seja, o conteúdo do elemento será analisado pelo processador que está lendo o arquivo XML

No documento XML:

<nome>João da Silva</nome>

Elemento Vazio

<!ELEMENT estudante EMPTY>

O elemento estudante não possui conteúdo

No documento XML:

<estudante/>

Elemento Misto

<!ELEMENT endereco (#PCDATA | cidade)*>

Elemento endereço possui texto, e subelemento(s) cidade

No documento XML:

Conteúdo Misto

- Existe uma regra importante que deve ser seguida quando existe escolha entre texto e elementos filho.
 - #PCDATA deve ser obrigatoriamente
 - o primeiro token no grupo
 - o grupo deve ser de escolha, opcional e com repetição.
 - Exemplo

<!ELEMENT endereco (#PCDATA | cidade)*>

Qualquer conteúdo

<!ELEMENT obs ANY>

 Neste exemplo, o elemento obs pode conter como conteúdo qualquer outro elemento que tenha sido declarado na DTD

Declaração de Atributos

- Declarados em uma declaração ATTLIST
 - Nome do elemento que contém o atributo
 - Lista de atributos
 - Para cada atributo da lista, devem ser declaradas as seguintes informações
 - nome do atributo
 - tipo do atributo (CDATA, ID, IDREF, etc.), ou lista de valores possíveis, separados por "|"
 - obrigatoriedade (#REQUIRED, #FIXED, #IMPLIED, ou um valor default para o atributo, informado entre aspas)

Exemplo

<!ATTLIST empregado cod CDATA #REQUIRED dept CDATA #REQUIRED

>

O elemento **empregado** possui dois atributos **cod**, e **dept**O tipo de ambos é um texto (**CDATA**), e ambos são obrigatórios (**#REQUIRED**)

Exemplo

<!ATTLIST empregado cod CDATA #REQUIRED dept CDATA #REQUIRED

>

No documento XML:

<empregado cod="E01" dept="D01">...

Cardinalidade

- Atributos obrigatórios: utiliza-se a palavra reservada #REQUIRED <!ATTLIST empregado cod CDATA #REQUIRED>
- Atributos opcionais: utiliza-se a palavra reservada #IMPLIED <!ATTLIST empregado dept CDATA #IMPLIED>
- Atributos com valores fixos: #FIXED + valor <!ATTLIST empregado empresa CDATA #FIXED "ABC">
- Atributos podem ter valores default <!ATTLIST empregado sexo (F | M) "F" > <!ATTLIST empregado sexo CDATA "F" >
- Neste caso, se o documento XML não fornecer o valor do atributo, o parser o adiciona automaticamente na hora do processamento

Declarações múltiplas

Um elemento pode ter mais de uma declaração de lista de atributos. Exemplo:

```
<!ATTLIST livro id ID #REQUIRED

tipo (romance| policial) #REQUIRED>
..... <!ATTLIST livro tipo (pocket| normal) #REQUIRED

autor CDATA #IMPLIED>
```

- A lista de atributos é combinada
- No caso de haver atributo com o mesmo nome, a primeira declaração é a que vale!

Tipos permitidos para atributos

- CDATA texto
- <ATTLIST documento versao CDATA #REQUIRED>
 Uso: <documento versao="10.10.2001">...</documento>
- NMTOKEN um name token

Não pode conter branco.

Aceita apenas *Letter* | *Digit* | '.' | '-' | '_' | ':')

- <ATTLIST documento digito_verificacao NMTOKEN #IMPLIED> Uso: <documento digito_verificacao="art1">...</documento>
- NMTOKENS vários name tokens
- <ATTLIST documento paginas NMTOKENS #IMPLIED> Uso: <documento paginas="elem10 elem45 el77 ar102">...</documento>

Tipos permitidos para atributos

- ► ENTITY entidade
- <ATTLIST figura arquivo ENTITY #REQUIRED>
 Uso: <figura arquivo="foto"/>
- ENTITIES várias entidades
- <ATTLIST figura arquivo ENTITIES #REQUIRED>
 Uso: <figura arquivo="foto1ano foto10anos foto15anos"/>

Mais detalhes sobre entidades podem ser encontrados no final deste material

Tipos permitidos para atributos

- ▶ ID um identificador → deve ter valor único no documento
- <ATTLIST capitulo Nr ID #REQUIRED>
 Uso: <capitulo Nr="A1">...</capitulo>
- Os valores para o tipo ID seguem as mesmas regras de construção de nomes de elementos (devem começar por letra, ":" ou "_")

- IDREF referência a um ID
- <ATTLIST referencia cap IDREF #REQUIRED>
 Uso: O capítulo <referencia cap="A1"/> mostra as características de ...
- IDREFS referência a vários IDs
- <ATTLIST referencia cap IDREFS #REQUIRED>
 Uso: Os capítulos <referencia cap="A2 A3"/> apresentam ...

Usando o ID e o IDREF

Na DTD:

<!ELEMENT capitulo(...)>

<!ATTLIST capitulo nr ID #REQUIRED>

<!ELEMENT referencia EMPTY>

<!ATTLIST referencia cap IDREF #REQUIRED>

Na instância (documento) XML

<capitulo nr="A1">

</capitulo>

<conclusao> Enfim, deve-se <a>.. Como apresentado inicialmente no capitulo <referencia cap="A1"/> deve-se tomar cuidado ao definir ...

</conclusao>

- Crie uma DTD para a receita médica definida no exercício da aula de Introdução (pegar arquivo no site da disciplina)
 - Modifique o documento para incluir a declaração da DTD
 - Teste declaração interna, e depois declaração externa

- Altere a DTD do exercício anterior para adicionar as seguintes características
 - um elemento vazio para o logo da clínica
 - um elemento observações que tenha como conteúdo QUALQUER elemento já definido nesta DTD
- Altere o documento XML de receita médica para que fique válido com a nova versão da DTD

- Acrescente à DTD do exercício anterior as seguintes informações na forma de atributos:
 - Data de criação da receita, obrigatória no documento
 - A descrição do logo da clínica, obrigatória
 - O tipo da figura que representa o logo, com valor default
 GIF e grupo de escolha: GIF, JPG e BMP
- Altere a definição do elemento observações. Agora ele deve ser declarado como um elemento com conteúdo misto e subelementos importante.

 Crie um documento XML que obedeça a seguinte DTD (artigo.dtd)

```
<!ELEMENT artigo (autor+, titulo, resumo, secao, bibliografia)>
<!ATTLIST artigo data CDATA #REQUIRED
    ultima revisao CDATA #IMPLIED ultimo revisor CDATA #IMPLIED
    versao CDATA #IMPLIED status CDATA #IMPLIED>
<!ELEMENT autor (nome)>
<!ELEMENT nome (#PCDATA)>
<!ELEMENT titulo (#PCDATA)>
<!ELEMENT resumo (#PCDATA)>
<!ELEMENT secao (#PCDATA|figura)*>
<!ELEMENT figura EMPTY>
<!ATTLIST figura nome CDATA #IMPLIED>
<!ELEMENT bibliografia (referencia)+>
<!ELEMENT referencia (obra, autor+, ano?, local?)>
<!ATTLIST referencia id ID #REOUIRED>
<!ELEMENT obra (#PCDATA)>
<!ELEMENT ano (#PCDATA)>
<!ELEMENT local (#PCDATA)>
```

Outras declarações na DTD

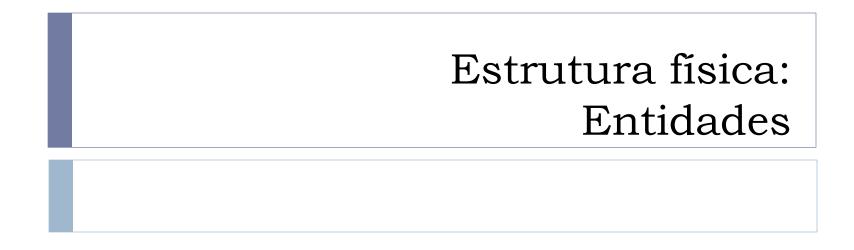
- Seções Condicionais
- Entidades de parâmetro

Declaração de Notação

Relacionadas à estrutura física dos Documentos XML.

Seções Condicionais

- Porções da DTD podem ser consideradas opcionais.
 Esta característica é fornecida pelo uso de seções condicionais
 - As seções que serão consideradas pelo processador XML devem ser marcadas como uma seção incluída .Por exemplo:
 - <![INCLUDE [..]]>
 - Para que ela n\u00e3o seja processada pelo processador XML, a palavra INCLUDE deve ser trocada por IGNORE, marcando uma se\u00e7\u00e3o ignorada :
 - <![IGNORE [..]]>



Entidades

- **USO:**
 - Separar um documento em vários
 - Permitir reuso
 - Ex.: Um livro onde cada capítulo é armazenado separadamente
 - Permitir inclusão de dados não XML
 - Ex.: As figuras utilizadas em um livro
- Podem ser dados XML ou arquivos binários

Conceitos

Declaração de entidade

Livro1.xml

```
<?xml version="1.0">
<!DOCTYPE livro SYSTEM "minhaDTD.dtd"</pre>
<!ENTITY capitulo1 SYSTEM "Doc1.xml">
vro>
   <titulo> </titulo>
   &capitulo1;
</livro>
```

Doc1.xml

Referência à entidade

Entidade externa

Entidade documento

Parsed × Unparsed

Entidade Parsed

- O conteúdo é considerado como parte integrante do documento e deve ser bem formado.
- Conteúdo é analisado pelo parser
- Documentos XML

Entidade Unparsed

- O conteúdo pode ser qualquer dado não-XML, arquivos binários, pdf, ps, etc, até mesmo conteúdo XML. Não existe restrição ao conteúdo deste tipo de entidade
- Conteúdo não é analisado pelo parser
- Normalmente utilizado para dados binários

Definição de uma Entidade

- Através de uma declaração
 - <!ENTITY ...>
- Deve ser definida antes de ser referenciada
- Nome é sensível a maiúsculas e minúsculas
- É possível definir a mesma entidade mais de uma vez, mas só a primeira será considerada pelo parser
 - <!ENTITY MinhaEntidade " ">
 - <!ENTITY MinhaEntidade " ">
- Uma entidade pode ser referenciada n vezes

Armazenamento de uma Entidade

- Dentro do documento XML
 - ENTIDADE INTERNA
 - Entidade de texto
- Em um arquivo separado
 - ENTIDADE EXTERNA
 - Entidade de texto
 - Entidade binária

Entidade de Texto Interna

- O conteúdo está contido entre " " . Exemplo
 - <!ENTITY xml "Extensible Markup Language">
- Ao ser referenciada o caracter "&" inicia a marcação e ";" finaliza. Por exemplo:
 - "... Em &xml; o conceito de entidades significa ..."
- O processador resolve:
 - "... Em Extensible Markup Language o conceito de entidades significa ..."

Entidade Externa (de texto e binária)

Uso de um verificador de sistema

Indicado pela palavra-chave SYSTEM

<!ENTITY minhaEnt SYSTEM "/ent/minhaEnt.xml">

Usando uma entidade

```
<para>...</para>
livro.xml
                                          capitulo1.xml
                                                                     <para>...</para>
<?xml version="1.0">
                                          <capitulo>
                                                                   </secao>
<!DOCTYPE livro SYSTEM "livro.dtd"[</pre>
                                            <secao>
                                                                   <secao>
<!ENTITY capitulo1 SYSTEM "capitulo1.xml">
                                              <para>...</para>
<!ENTITY capitulo2 SYSTEM "capitulo2.xml">
                                                                     <para>...
                                              <para>...</para>
<!ENTITY capitulo3 SYSTEM "capitulo3.xml">
                                                                   </secao>
1>
                                            </secao>
                                                                 </capitulo>
<livro>
                                            <secao>
   <titulo> </titulo>
                                              <para>...
   *&capitulo1; **.
                                            </secao>
   &capitulo2;
                                          </capitulo>••
                                                          capitulo2.xml
   .&capitulo3;
                                                          <capitulo>
                                                            <secao>
                                                              <para>...</para>
                                                              <para>...</para>
livro.dtd
                                                            </secao>
                                                            <secao>
<!ELEMENT livro(titulo, capitulo+)>
                                                              <para>...
<!ELEMENT titulo(#PCDATA)>
                                                            </secao>
<!ELEMENT capitulo(secao+)>...
                                                          </capitulo>
<!ELEMENT secao(para+)>
```

capitulo3.xml

<capitulo>
 <secao>

Analisando o exemplo...

- Percebemos que uma entidade é conteúdo!
 - São definidas no documento XML

```
<?xml version="1.0">
<!DOCTYPE livro SYSTEM "livro.dtd"[
<!ENTITY cap1 SYSTEM "capitulo1.xml">
<!ENTITY cap2 SYSTEM "capitulo2.xml">
<!ENTITY cap3 SYSTEM "capitulo3.xml">
]>
...
```

- Na DTD define-se APENAS a estrutura, jamais as entidades
 - Caso contrário existirá mistura de estrutura com conteúdo

Entidades built in

- O processador XML possui algumas entidades prédefinidas
 - < produz <</p>
 - > produz >
 - & amp; produz &
 - ' produz '
 - " produz "

Entidades de parâmetro

- Elementos com conteúdo de escolha que são comuns em um conjunto de documento, podem ser definidos como entidades. Ex:
 - <!ENTITY %comum "(parag | lista | tabela)">
- Dentro da declaração de elemento:

```
<!ELEMENT capitulo ((%comum;)*, secao*) >
```

- <!ELEMENT secao ((%comum;)*) >
- Procurar utilizar "()" para separar o quantificador
- Utilizar exclusivamente em DTDs (estas entidades definem estrutura, e não conteúdo)

Reuso de entidades de texto interna

- Reuso de definição de entidade de texto interna
- Usa-se no topo do XML, juntamente com a definição das demais entidades:

```
<DOCTYPE livro SYSTEM "livro.dtd"[
<!ENTITY % minhasEntidades SYSTEM "mEnt.ent">
%minhasEntidades;
]>
```

O arquivo mEnt.ent pode conter, por exemplo:

```
<!ENTITY xml "eXtensible Markup Language">
<!ENTITY html "HyperText Markup Language">
<!ENTITY sgml "Standard Generalized Markup Language">
```

Reuso de entidades de parâmetro

- Reuso de definição de entidade de parâmetro
- Usa- se na DTD

```
<!ENTITY % minhasEntPar SYSTEM "mEntPar.ent">
%minhasEntPar;
Vejam que isso permite que
a DTD seja dividida em vários
```

arquivos

O arquivo mEntPar.ent pode conter:

```
<!ENTITY % comum "(lista, tabela)">
<!ENTITY % parRef "(paragrafo, referencia)">
<!ENTITY % endereco "(rua, numero, bairro)">
```

Entidades Binárias

Uso de SYSTEM – porque é externa!!

- Formatos não XML.
 - Exemplo de definição:
 - <!ENTITY foto SYSTEM "/ent/foto.gif" ...>
- Ao referenciá- la no texto:
 - Foto de Fulano de Tal:<IMAGEM nome="foto"/>
 - ▶ Referenciar somente como valor de atributo, sem & e ;
 - O atributo deve ser do tipo ENTITY ou ENTITIES

Entidades Binárias

- Uma entidade binária não é um documento XML
- Como indicar ao processador que a entidade binária é unparsed, e qual aplicação é capaz de processála??

 Necessário o uso de notação => Estas declarações devem ser feitas DENTRO do documento XML

- <!NOTATION GIF SYSTEM "c:/gimp/gimp.exe">
- <!ENTITY foto SYSTEM "/ent/foto.gif" NDATA GIF>

Notações

- Uso da aplicação que indica o software que processa a notação é opcional
 - Forma mínima:
 - <!NOTATION GIF SYSTEM "">
- Uso do tipo de entidade, quando binária, é obrigatório

<!ENTITY foto SYSTEM "/ent/foto.gif" NDATA GIF>

Entidades Binárias – exemplo

Na DTD:

```
<!ELEMENT figura EMPTY>
<!ATTLIST figura nome ENTITY #REQUIRED>
```

No documento XML:

```
<!NOTATION GIF SYSTEM "c:/gimp/gimp.exe">
<!ENTITY foto SYSTEM "/ent/foto.gif" NDATA GIF>
...

<figura nome="foto"/>
```

- Locais que uma entidade pode ser referenciada:
 - Dentro do conteúdo de texto de um elemento
 - Em um atributo
 - Em um valor de uma entidade
 - Dentro das declarações de construtores da DTD
 - No entanto, existem restrições dependendo de onde ela é referenciada

- Entidades de texto não podem aparecer nas DTD.
 - Exemplo abaixo está ERRADO
 - <!ELEMENT paragr(#PCDATA | Emph | &Entidade;)>

 Atributos não podem referenciar uma entidade de texto EXTERNA, mas podem referenciar uma entidade de texto INTERNA.

```
<!ENTITY Empresa "Minha Empresa">
<!ENTITY Endereco SYSTEM "endereco.xml">
```

. . .

<livro proprietario="&Empresa; em &Endereco;">









- O uso de entidades binárias só é permitido como conteúdo de atributos
- NA DTD:

```
<!ELEMENT fig EMPTY>
<!ATTLIST fig nome ENTITY #REQUIRED>
```

No Documento XML:

```
<!DOCTYPE titulo SYSTEM "titulo.dtd"[
<!NOTATION TIFF SYSTEM "c:/gimp/gimp.exe">
<!ENTITY MinhaFig SYSTEM "../figuras/fig.tif" NDATA TIFF>
]>
<titulo>
    Relato <fig nome="MinhaFig"/>
</titulo>
```

Gerenciamento de Entidades

Uso de identificadores

 Um gerenciador de entidade usa um identificador para localizar entidades externas

Mecanismo adicional

 Usar identificador público indicado pela palavra-chave PUBLIC

<!ENTITY minhaEnt</pre>

PUBLIC "-//MinhaEmpresa/Entidades Superscript Charts//EN...">

Usado para manter a compatibilidade com o SGML

Gerenciamento de Entidades Externas

- Uso de identificadores públicos formais
 - Estrutura rígida composta por:
 - Tipo do identificador (PUBLIC entidade de domínio público)
 - Identificador proprietário (+ proprietário registrado(padrão), proprietário não registrado)
 - Classe de texto público (em XML pode ser DTD, Entidades ou Notações)
 - Descrição de texto público (fornece informação adicional)
 - Linguagem de texto público (linguagem usada)
- Exemplo:

```
<!ENTITY ... PUBLIC "+//MyCorp//TEXT...">
<!ENTITY ... PUBLIC "-//MyCorp//ENTITY Superscript Chars//EN" >
<!ENTITY ... PUBLIC "ISO 8879:1986//...">
```

Exercício 5

- Altere a receita médica para incluir a imagem do logo da clínica e da assinatura do médico.
- É necessário alterar o documento XML e a DTD? Ou só o documento XML?

Exercício 6

 Separe o conteúdo da receita médica em vários arquivos XML, cada um contendo um medicamento